

南開大學
Nankai University

计算机学院

自然语言处理实验报告

作业一：文本分类实现

姓名：周宇

学号：2311999

专业：计算机科学与技术

2026 年 10 月 11 日

Abstract

本文围绕新闻文本分类任务，对三类文本表示方法进行了实现与比较：词袋模型、静态词向量和预训练语言模型。实验以 New York Times（NYT）新闻为分类数据，统一按照 80%/10%/10% 划分训练集、验证集和测试集，并使用 Accuracy 与 Macro-F1 作为评价指标。Task 1 使用 Binary Bag of Words 和 Word Frequency 表示，并训练 Logistic Regression 分类器；Task 2 分别使用预训练 GloVe、在 AG News 上训练的 Word2Vec、在 NYT 训练集上训练的 Word2Vec，将词向量平均作为文档表示；Task 3 对 `google-bert/bert-base-uncased` 进行三轮微调。最终测试结果表明，Word Frequency 在本数据集上取得最高的 Accuracy（0.9878）和 Macro-F1（0.9704）；BERT 第三轮最终模型的 Accuracy 为 0.9809，Macro-F1 为 0.9557。实验说明，在类别与关键词高度相关、训练数据规模有限且 BERT 输入长度受限的新闻分类场景中，简单的词频表示仍具有很强的竞争力。

1 实验目标与任务

本实验的目标是掌握文本分类的一般流程，并比较不同文本表示方法对分类性能的影响。具体任务如下：

1. 使用 Binary Bag of Words 和 Word Frequency 构造文档特征，并使用 Logistic Regression 完成 NYT 新闻分类；
2. 使用 100 维预训练 GloVe、AG News Word2Vec 和 NYT Word2Vec 构造平均词向量，并使用 Logistic Regression 分类；
3. 使用 `bert-base-uncased` 完成端到端微调，最大序列长度设为 64，训练 3 个 epoch；
4. 在完全相同的 NYT 数据划分上，以 Accuracy 和 Macro-F1 评价各方法，并对结果进行比较分析。

2 数据集与实验设置

2.1 数据集

NYT 数据集包含 `text` 和 `label` 两列，标签包括 `business`、`politics` 和 `sports`。AG News 数据集仅在 Task 2 中用于训练 Word2Vec 词向量。所有分类器均在 NYT 数据上训练和评价。

实验首先使用随机种子 67 对 NYT 数据进行分层随机划分，训练集、验证集和测试集比例分别为 80%、10% 和 10%。三个任务均复用相同的划分，避免因数据不同造成不可比的结果。数据规模与类别分布见表 1。

表 1: NYT 数据划分与类别分布

数据集	Business	Politics	Sports	总数
Training Set	1143	1161	6911	9215
Validation Set	143	145	864	1152
Test Set	143	145	864	1152

由表 1 可见，`sports` 占测试集的 75%，数据存在明显的类别不均衡。因此，除 Accuracy 外，还必须关注对各类别等权平均的 Macro-F1。

2.2 评价指标

设测试集样本数为 N，预测正确的样本数为 N_{correct}，则 Accuracy 定义为

$$\text{Accuracy} = \frac{N_{\text{correct}}}{N}. \tag{1}$$

对于类别 c，Precision、Recall 和 F1 分别为

$$P_c = \frac{TP_c}{TP_c + FP_c}, \qquad R_c = \frac{TP_c}{TP_c + FN_c}, \tag{2}$$

$$F1_c = \frac{2P_cR_c}{P_c + R_c}. \tag{3}$$

若类别总数为 C，则 Macro-F1 为

$$\text{Macro-F1} = \frac{1}{C}\sum_{c=1}^{C} F1_c. \tag{4}$$

Macro-F1 对每个类别赋予相同权重，能够避免多数类对总体结果的掩盖。

2.3 统一实验环境

实验使用 Python 实现，主要依赖包括 NumPy、Pandas、SciPy、scikit-learn、Gensim、PyTorch 和 Transformers。传统方法统一使用 Logistic Regression，默认正则化参数为 $C = 1.0$，求解器为 L-BFGS，最大迭代次数为 1000。所有可控随机过程均设置随机种子 67。

3 Task 1：Bag of Words

3.1 Binary Bag of Words

首先仅使用 NYT 训练集建立 unigram 词表，最终词表大小为 61,081。设词表大小为 $|V|$，文档 d 的第 i 维特征定义为

$$x_i = \begin{cases} 1, & \text{词} v_i \text{ 出现在文档} d \text{ 中}, \\ 0, & \text{否则}. \end{cases} \tag{5}$$

该表示只保留词是否出现，不考虑出现次数。实现中使用稀疏矩阵存储特征，从而避免直接构造高维稠密矩阵。

3.2 Word Frequency

Word Frequency 与 Binary Bag of Words 使用同一个训练集词表，但每一维记录对应词在文档中的实际出现次数：

$$\boldsymbol{x}_d = (c_1, c_2, \ldots, c_{|V|}), \tag{6}$$

其中 c_i 表示词 v_i 在文档 d 中出现的次数。该方法在保留关键词身份的同时，也保留了关键词在当前文档中的频率信息。

3.3 实验结果与分析

Task 1 的结果见表 2。

表 2: Task 1 实验结果

方法	数据集	Accuracy	Macro-F1
Binary Bag of Words	Validation	0.9835	0.9599
Binary Bag of Words	Test	0.9826	0.9622
Word Frequency	Validation	0.9896	0.9741
Word Frequency	Test	**0.9878**	**0.9704**

Word Frequency 在测试集上的 Accuracy 和 Macro-F1 分别比 Binary Bag of Words 高约 0.52 和 0.83 个百分点。这说明对于 NYT 新闻分类，类别相关词语的出现次数具有额外判别力。例如体育报道中球队名、赛事名和比赛相关词可能反复出现，而 Binary Bag of Words 会丢弃这种频率差异。

4 Task 2：Word Embedding

4.1 文档向量构造

Task 2 统一使用 100 维词向量。文本转换为小写后，使用正则表达式提取字母和数字组成的 token。对于包含 n 个有效词的文档 d，文档向量为所有已知词向量的平均：

$$\boldsymbol{e}(d) = \frac{1}{n} \sum_{i=1}^{n} \boldsymbol{e}(w_i). \tag{7}$$

若一个词在文档中多次出现，则会多次参与平均，因此该表示仍以隐式方式包含词频信息。三个实验得到文档向量后，均使用与 Task 1 相同类型的 Logistic Regression 分类器。

4.2 三组词向量实验

Pre-trained GloVe 使用 `glove.6B.100d` 预训练词向量。该模型由大规模通用语料训练，能够覆盖绝大多数 NYT token。

Word2Vec Trained on AG News 使用 AG News 的 90,000 篇文本训练 Skip-gram Word2Vec。主要参数为：`vector_size=100`、`window=5`、`min_count=2`、`sg=1`、`epochs=10`、`workers=1` 和 `seed=67`。

Word2Vec Trained on NYT 仅使用 9,215 条 NYT 训练集文本训练 Word2Vec，不使用验证集和测试集文本，避免信息泄漏。模型参数与 AG News Word2Vec 完全相同。

4.3 实验结果与分析

Task 2 的结果和测试集 token 覆盖率见表 3。所有测试文档均至少包含一个可识别词，因此不存在全零文档向量。

表 3: Task 2 实验结果

方法	数据集	Accuracy	Macro-F1	Token Coverage
GloVe	Validation	0.9774	0.9468	0.9979
GloVe	Test	**0.9792**	**0.9549**	**0.9977**
AG News Word2Vec	Validation	0.9661	0.9183	0.9736
AG News Word2Vec	Test	0.9714	0.9384	0.9730
NYT Word2Vec	Validation	0.9757	0.9425	0.9929
NYT Word2Vec	Test	0.9757	0.9473	0.9925

预训练 GloVe 在 Task 2 中表现最好。其测试集 token 覆盖率达到 0.9977，说明大规模预训练语料提供了较完整的词汇覆盖。NYT Word2Vec 虽然训练语料较小，但与目标领域一致，因此优于 AG News Word2Vec。AG News Word2Vec 使用的语料规模更大，但存在领域差异，且测试集覆盖率最低，最终 Macro-F1 也最低。

三种平均词向量方法均低于 Task 1 的词袋方法。主要原因是平均操作将整篇新闻压缩为 100 维向量，丢失了词序、局部组合和具体关键词的独立维度；多个语义不同的文档也可能得到相近的均值向量。相比之下，61,081 维词袋特征能够直接保留大量具有类别区分力的专有名词和主题词。

5 Task 3：BERT Fine-tuning

5.1 模型与训练设置

Task 3 使用 `google-bert/bert-base-uncased`，在模型顶部加入三分类线性分类头。标签映射为 `business=0`、`politics=1`、`sports=2`。分词时统一设置 `max_length=64`，超过长度的文本截断，不足部分填充。

训练参数见表 4。优化器使用 AdamW，并采用带 10% warmup 的线性学习率调度；梯度裁剪阈值为 1.0。

表 4: BERT 微调参数

参数	设置
Pre-trained model	`google-bert/bert-base-uncased`
Maximum sequence length	64
Number of epochs	3
Train batch size	32
Evaluation batch size	64
Learning rate	2×10^{-5}
Weight decay	0.01
Warmup ratio	0.10
Random seed	67

5.2 训练过程

每个 epoch 结束后在验证集上计算损失、Accuracy 和 Macro-F1，训练过程见表 5。

表 5: BERT 三轮训练过程

Epoch	Train Loss	Validation Loss	Validation Accuracy	Validation Macro-F1
1	0.2674	0.0814	0.9731	0.9400
2	0.0521	0.0754	**0.9757**	**0.9443**
3	0.0168	0.0905	0.9748	0.9407

第 2 轮取得最佳验证集 Macro-F1，但作业要求训练 3 个 epoch 后在测试集评价，因此正式结果使用第 3 轮结束时的 final checkpoint，而不是根据验证集选择的第 2 轮 checkpoint。第 3 轮训练损失继续下降，但验证损失上升，说明模型已经出现轻微过拟合。

5.3 测试结果

第 3 轮 final checkpoint 在测试集上的结果见表 6。

表 6: Task 3 测试结果

模型	Accuracy	Macro-F1
BERT-base-uncased（Epoch 3 Final）	0.9809	0.9557

BERT 的 Accuracy 和 Macro-F1 均高于三种平均词向量方法，说明上下文编码能够提升整体分类能力；但其两个指标仍未超过词袋方法。一个重要原因是 NYT 新闻通常较长，而实验按要求只保留前 64 个 token，正文后续信息无法进入模型。此外，训练集规模较小、类别不均衡以及固定的三轮训练设置也限制了 BERT 的优势。

6 总体结果比较

六种方法在 NYT 测试集上的最终结果见表 7，按 Accuracy 从高到低排列。

表 7: 所有方法的测试集结果汇总

排名	方法	Accuracy	Macro-F1
1	Word Frequency	**0.9878**	**0.9704**
2	Binary Bag of Words	0.9826	0.9622
3	BERT-base-uncased（Epoch 3 Final）	0.9809	0.9557
4	Pre-trained GloVe 6B 100d	0.9792	0.9549
5	Word2Vec Trained on NYT Train	0.9757	0.9473
6	Word2Vec Trained on AG News	0.9714	0.9384

从结果可以得到以下结论：

1. **Word Frequency 效果最好。** NYT 三分类任务与主题关键词高度相关，词频表示既保留具体词项，又保留词项强度，因此在当前数据上优于更加复杂的表示方法。

2. **预训练词向量优于自行训练的词向量。** GloVe 依靠更大规模语料获得更高覆盖率和更稳定的语义表示。NYT Word2Vec 得益于领域一致性，优于 AG News Word2Vec。

3. **平均词向量存在信息瓶颈。**无论词向量来源如何，将整篇新闻压缩为单个 100 维均值向量都会损失关键词位置、词序和组合关系。

4. **BERT 并未必然取得最优结果。** BERT 具有上下文建模能力，但本实验只输入前 64 个 token，且类别不均衡、训练数据有限。BERT 最终排名第三，说明模型复杂度并不直接等价于更高的任务性能。

5. **Macro-F1 必不可少。**由于 Sports 是多数类，各方法的 Macro-F1 普遍低于 Accuracy。仅报告 Accuracy 可能高估模型对 Business 和 Politics 的分类能力。

7 结论

本文完成了词袋模型、静态词向量和 BERT 三类文本表示方法的新闻分类实验。所有方法均在相同的 NYT 数据划分上进行评价。最终 Word Frequency 取得 0.9878 的 Accuracy 和 0.9704 的 Macro-F1，为本实验最佳方法；BERT 第三轮最终模型取得 0.9809 的 Accuracy 和 0.9557 的 Macro-F1。实验结果表明，模型选择应结合数据规模、文本长度、类别特征和计算成本。对于当前 NYT 数据，具有高维稀疏关键词特征的词频模型最适合；平均词向量虽然计算高效，但存在明显的信息压缩损失；BERT 能够利用上下文信息，但需要更长输入、更多数据或更充分的超参数调节才能发挥更明显的优势。